七道闸门

一个 AI 产品的验收实录

> 上线之前，先回答一个问题：凭什么可以上线。

把工程验收的七道门，搬到 AI 产品上。每一道门只回答三件事：标准是什么、证据在哪、放不放行。

作者：刘恺希 | 7 道闸门 · 4 个 JD 职责全覆盖 · G3/G4 核心章节 | PDF 版 ↓ | 证据包 ↓ | 一页投递版 ↓ | 交付推演 ↓

联系我

邮箱：1010587473@qq.com

微信：扫码添加，备注「作品集」

角色边界

本人负责需求拆解、评测设计、规则与阈值调优、系统验证和 UAT；OCR 与大模型调用现成能力，未做模型训练。项目为个人自建，非公司项目；访谈、UAT 与 bug 记录均来自本人执行的真实过程。

7
道验收闸门
需求 → 上线后

251
条评测检查点
项目A 669 份文件 / 项目B 342 份

−12.9
跨项目 F1 点
同阈值 0.40，项目A→项目B

01	02	03	04	05	06	07
需求	**方案**	**数据**	**模型**	**系统**	**UAT**	**上线后**
● 通过	● 通过	● 有条件**核心章节**	● 有条件**核心章节**	● 通过	● 有条件	● 通过

■ 真实项目数据 ■ 亲历 / 自建 ■ 模拟或经验判断

本页数字来自本人自建项目 T1-02 的评测记录；3 场访谈（2026-11-03）、1 人 UAT（2026-10-31）与 8 条 bug 记录均已完成；估算与单样本口径已在对应位置标注。

00 / 立项依据

为什么是这个场景

先说清楚：不是「我想做个 AI」，是「这个环节每年在返工」。这一段对应 JD 的商业分析与需求管理。

现在他们怎么做

人工翻清单

对着归档范围逐项翻目录

一套资料 1–2 天；漏项靠经验

Excel 台账

自己维护一份缺项表

版本多、不同步、无法追溯条款

通用 OCR

把扫描件转文字再搜

能搜到字，不能判断「该不该有」

直接问大模型

把目录贴进去问缺什么

会编；无法给出可核对的依据

替代方案对比（1 页，不写市场规模）

方案	能做到	做不到	为什么不够
人工自查	理解上下文、能拍板	慢、依赖个人经验、无留痕	一套 220kV 线路资料六百多份，2–3 名资料员要核对 1–2 天；漏项靠经验，核对完没有留痕。
Excel 台账	可自定义	不校验、不联动、换人就断	项目管理人员常驻现场，台账只能加班补；换人后无人接手，版本随即断更。
通用 OCR / 检索	找到字	判断不了文种、卷册、签章关系	只能命中字面；文件多、相似文件多时，仍要逐份人工确认该不该用。
大模型直接问答	会解释、会总结	幻觉、无依据、不可验收	文件内容相似但主体、数据不同，容易把不同文件的内容拼在一起；给出的缺项也无法回溯到条款。

来源：3 场访谈（2026-11-03，佛山，资料员 / 项目经理 / 监理）+ 4 年电力项目资料经验。

价值假设（不写市场规模）

谁用

资料员 / 项目经理 / 监理

一线执行 + 复核

价值

一套资料从 1–2 天压到 20 分钟

2026-11-03，项目A，669 份，单次；人工 2 人 × 6.5 h = 13 人时；系统 18 min；另人工复核 8 min。

成本

开发 + 推理 + 维护

口径：OCR 16 份 77 秒；LLM 15 条 30 次调用 ≈ 5.8 万输入 token，按 ¥1/¥2 每百万估算约 ¥0.06；全检 170 条约 ¥0.7（峰值约 ¥1.4），非账单。

不做什么

不判断内容真伪、不替代签字

责任边界

我们的位置

不是「更准」，是**可验收、可追溯、可人工兜底**。准确率不是卖点，敢让人核对才是。

01-07 / 门

七道闸门

每道门只回答三件事：标准是什么、证据在哪、放不放行。点封面上的门可以直接跳到对应段落。**G3 数据与 G4 模型是核心章节**——这个岗位最看重的不是 AI 能不能做，而是能不能用数字说清「好了没有」；其余五道门证明流程完整。

01

需求

这个需求可测试吗？

通过

> 需求不是「帮我检查资料」，是「在 20 分钟内告诉我缺哪几份、依据哪一条、谁去补」。

方法： 3 场访谈已完成（2026-11-03，佛山），每场 45 分钟；对象为资料员 / 项目经理 / 监理。提纲固定 5 问，不诱导结论。

5 个关键发现（访谈原话，2026-11-03）

- 资料员：「就对着归档目录一页页翻，先按分部，再按卷。缺什么基本靠记，翻完就过去了，没人留个清单。」 真实项目数据
- 资料员：「见证取样和验收记录。它们散在几个卷里，名字还不一样，少一份当时看不出来，后面要返工。」 真实项目数据
- 资料员：「上次监理说少一份检测报告，我们从下午翻到第二天，最后在一个临时文件夹里找到，送审就晚了。」 真实项目数据
- 项目经理：「先给我一张缺项清单，写清楚谁去补、依据哪一条，我好分工。」 真实项目数据
- 监理：「把『疑似』说成『确定』，或者引用对不上。一次两次我就不看了。」 真实项目数据

痛点 → 需求 → 可验证的验收标准

痛点（原话）	需求	验收标准（Given / When / Then）
资料员：「就对着归档目录一页页翻……翻完就过去了，没人留个清单。」	送审前知道缺什么	给定一套资料目录，当系统完成检查，则输出缺项清单，每条带条款编号与原文位置
监理：「缺项清单写得太笼统……不说少哪一份、依据哪一条。」	能向监理解释为什么缺	给定任一缺项，当点击详情，则显示归档范围条款、判定依据、置信度
资料员：「它要是给我编一个文件名……我以后就不敢用了。宁可说没找到。」	不确定的不要瞎猜	给定低置信项，当系统无法确认，则明确显示「未找到」，不得编造文件名

每条需求都必须能写成 Given/When/Then；写不成的，退回业务方，不进需求池。

> **被拒绝的需求：**「自动判断资料内容真假。」
> 拒绝理由：不可验收（没有 ground truth）、责任边界不清（真伪判定涉及法律责任）、幻觉后果不可兜底。
> 改为：**输出「疑似」+ 原文依据 + 人工确认**，系统不签字。

3 条 User Story（由访谈归纳）

- 作为资料员，我希望导入一套资料后 20 分钟内看到缺项清单，以便在送审前补齐。 自建评测
- 作为项目经理，我希望每个缺项都能追溯到归档范围条款，以便向监理解释。 自建评测
- 作为监理，我希望系统明确标出「未找到」而不是猜，以便决定是否人工复核。 自建评测

本门判断

需求能不能被测试，决定了后面六道门有没有意义。**写不成验收标准的需求，不是需求，是愿望。**

本门决定 · 放行　通过：3 条需求均可写成 Given/When/Then；1 条需求被拒并记录理由。

访谈记录已归档（3 场，2026-11-03）　需求池按 MoSCoW 排序　被拒需求留痕

02

方案

AI 该介入到哪一步？

通过

> AI 的价值不是替人做决定，是把人从「翻 669 份文件」变成「看 44 条疑似」。

人 / 规则 / AI / 人审 AI 的分工

步骤	谁做	为什么	失败怎么办
资料目录解析	规则	文件名、路径、文号是结构化信号，不需要模型	解析失败 → 转人工导入
检查点匹配	规则 + 3-gram + 同义词 + 文件夹兜底	可解释、可校准、可复现	低于阈值 → 标「未找到」，不猜
疑似带复判	LLM（仅 0.40–0.62）	缩小人工范围，不替代判定	输出「疑似 + 依据」，必须人工确认
最终判定 / 签字	人	责任边界；系统不承担验收责任	人可推翻系统结论
导出整改表	规则	固定模板，字段可控	失败给明确错误提示

跨职能接口（我怎么和四方对齐）

角色	我提供	我需要	对齐频率
算法工程师	评测集、指标口径、阈值与门禁	模型分数、延迟、失败样本	每周
前端 / 后端	验收标准、异常用例、失败兜底文案	接口、埋点、错误码	每次迭代
设计师	用户流程、AI 失败后的界面状态	原型、交互与提示文案	评审节点
业务 / 客户	访谈提纲、UAT 脚本、放行条件	真实场景、数据、验收反馈	双周

协作不是「拉个群」，是每一方都知道自己交付什么、什么时候交、交错了怎么办。

如果放进真实客户项目：90 天交付推演（假设）

时间（周）	关键动作	退出条件（谁签字）
1–2	**立项**：访谈项目经理 / 资料员 / 监理；做一次人工基线计时；确认只做辅助自查，把判真假、代签字写进不做清单。	项目经理确认范围；监理确认抽检口径
3–6	**进场**：内网部署、脱敏/合成数据跑通、申请 1 套资料只读；和资料员标 100 个检查点，按客户数据重扫阈值，不搬项目A 的 0.40。	IT 安全签字；项目经理 + 监理确认校准口径
7–8	**试点**：2 名资料员、3 个任务，每周 2 小时；只观察不提示；P1 48 小时内修；每周给项目经理一页进展。	无 P0/P1 未闭环；3/3 任务独立走通
9–12	**验收**：监理抽 20 条核对引用；整理已知限制；培训与 runbook；回滚演练；上线后连续 2 周周报。	引用可核对 ≥90%；签有条件接收；运维 owner 接手

完整一页推演（含目标门槛与 5 条风险应对）见 one-page/真实交付版推演-20261103.pdf。**这是假设推演，不是已发生的客户项目**；目标值是建议门槛，不是已达成结果。

用户流程（可运行系统，3 步）

- 导入一套资料目录 → 解析 → 按归档范围检查。 真实项目数据
- 看缺项清单：每条带条款、原文位置、置信度。 真实项目数据
- 导出整改表 → 人工复核 → 关闭。 真实项目数据

失败兜底（三条硬规则）

- 无依据 → 明确说「未找到」，不生成文件名。 真实项目数据
- 低置信（0.40–0.62）→ 转人工，不直接给结论。 真实项目数据
- 模型不可用 / 超时 → 降级到纯规则模式，功能可用但提示「未复判」。 自建评测

延迟与成本预算

环节	实测 / 预算	约束	降级策略
OCR（16 份扫描件）	约 77 单次实测 n=1，待复测	单套资料可接受	分批处理 + 进度提示
LLM 疑似复判	仅对 0.40–0.62 调用	控制成本与延迟	超时跳过，标「未复判」
全流程	单次 18 分钟（n=1）；P50 / P95 待补测	20 分钟内出清单	先出规则结果，再补复判

77 秒来自本项目 16 份扫描件的实测；换设备/换模型需重测。

技术边界：为什么现在不用 Agent / 端到端多模态

不用 Agent： 任务可以拆，但责任不能拆。多步自主决策在验收场景里无法逐步兜底，出错后无法定位是哪一步。

不用端到端多模态： OCR + 规则已经够用；VLM 会引入不可解释的误差，反而增加验收成本。

什么条件下才升级： 每一步可验证、失败可回滚、责任可落到人——三条同时满足才考虑。

本门判断

AI 只做「缩小人工范围」，不做「替人签字」。**边界写进 PRD，不是写进口号。**

本门决定 · 放行 通过：AI 介入点、失败兜底、延迟预算均已定义；AI 不承担最终判定。

分工图进 PRD　兜底规则进测试用例　技术边界写进方案评审记录

03 数据

评测集可信吗?

核心章节

有条件

> 评测集不是「找 50 个例子」，是「让系统最容易漏掉的例子也有机会进来」。

评测集构成

项目	检查点	文件数	有答案	用途
项目A（自校准）	251	669	151	建阈值、做消融
项目B（迁移验证）	251	342	126	验证跨项目泛化
合计	502	1,011	277	—

两条项目各 251 个检查点；「有答案」指该检查点在归档范围内确实应有文件。

候选池怎么来的（防止只测系统找得到的）

- 系统 top-5 候选 自建评测
- 文件 3-gram top-5 候选 自建评测
- 同卷 / 同分类号候选 自建评测
- 三路合并后人工标注「有 / 无 / 疑似」 自建评测

标注协议

- 有答案：归档范围内应有该文件，且能找到具体文件。 自建评测
- 无答案：归档范围不要求，或项目确实没有归档。 自建评测
- 疑似：存在相近文件但文种/卷册不完全对应，需人工确认。 自建评测
- 同一路径才算正确；标注前先写同义词，避免「先看系统答案再改口径」。 自建评测

> **主动写局限（不藏）**
>
> 单人标注，**无双人 Kappa**；样本来自 2 个项目；251 条检查点里严格判定只有 47–53 条，置信区间不窄。这些是方法短板，不是可以省略的脚注。

本门判断

评测集的可信度，不取决于样本多大，取决于**候选池有没有故意放进系统不擅长的例子。**

本门决定 · 有条件放行 有条件通过：评测集可用于本项目决策；跨项目结论需重标、重校准后才成立。

补双人标注（下一步） 扩大无答案样本 每项目独立校准

04

模型

指标过线了吗?

核心章节

有条件

> 模型指标不是越高越好，是「在这个业务代价下，哪个错误更不能接受」。

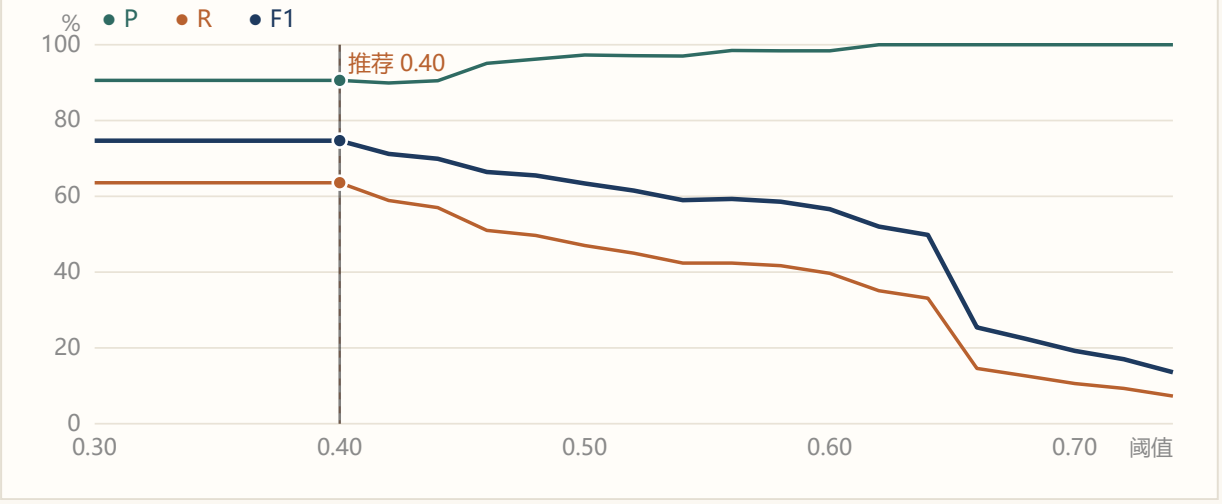
指标定义与口径

指标	定义	本页口径
P（准确率）	系统判「有」的里面，真正对的占比	严格 ≥0.62；含疑似 ≥0.40，两个数分开写
R（召回率）	有答案的检查点里，被系统找到的占比	同上；分母是有答案检查点
F1	P 与 R 的调和平均	不单独用于放行，必须同时看 P/R
幻觉率	见下方三口径	实测 15 条：原始无依据 1/14；引用/责任闸门后 0/13
延迟	P50 / P95	单次 18 分钟（n=1）；P50 / P95 待补测
成本	单次检查 token 成本	估算：15 条 30 次 ≈ 5.8 万输入 token，约 ¥0.06；全检 170 条约 ¥0.7（峰值 ¥1.4），非账单

阈值滑杆：自己拉一下，看结论怎么翻转

数据来自 251 条真实检查点的逐条预测。移动滑杆，P / R / F1 与放行判断实时变化。0.40 以上含疑似带，这里是「含疑似」口径；0.62 以上是「严格」口径。虚线是各项目的推荐阈值。

项目A（自校准） 项目B（迁移验证）



P 准确率
90.6%

R 召回率
63.6%

F1
74.7%

系统判定条数
106
/ 151 有答案

辅助自查：可放行
自动判定仍不可放行——R 未达 90%。

0.30 0.74 当前 0.40

当前 **0.40**：会提示 **106** 条，漏掉约 **55** 条（共 151 条有答案）。 推荐阈值 0.40 是 5 折自校准的结果，不是拍脑袋。

关键阈值点（真实评测结果）

项目	阈值来源	阈值	P	R	F1	判定 / 应找
项目A	5 折自校准	0.40	90.6%	63.6%	74.7%	106 / 151
项目A	固定高置信	0.62	100.0%	35.1%	52.0%	53 / 151
项目B	5 折自校准	0.42	76.7%	52.4%	62.3%	86 / 126
项目B	沿用项目A阈值	0.40	73.6%	53.2%	61.8%	91 / 126

0.40 行是「含疑似」口径；0.62 行是「严格」口径。两个数不能混着说：0.40 把疑似带也算进系统判定，0.62 只算高置信。

跨项目迁移：阈值能不能直接搬？

方向	阈值	P	R	F1	相对自校准
项目A（自校准）	0.40	90.6%	63.6%	74.7%	—
项目A → 项目B	0.40	73.6%	53.2%	61.8%	−12.9 点
项目B（自校准）	0.42	76.7%	52.4%	62.3%	+0.5 点（对 0.40）
项目B → 项目A	0.42	89.9%	58.9%	71.2%	−3.5 点

结论：阈值迁移掉 3.5–12.9 个 F1 点；按项目重校准只补回 0.5 个点。**差距主要来自数据，不是阈值。**

消融：每个模块到底贡献了多少

配置	P	R	F1	F1 变化
完整方案	90.6%	63.6%	74.7%	—
去掉同义词	88.0%	58.3%	70.1%	−4.6 点
去掉文件夹后缀	90.1%	60.3%	72.2%	−2.5 点
全部去掉	87.5%	55.6%	68.0%	−6.7 点

字符 3-gram baseline 的 F1 约 12%；完整方案 74.7%，+62.7 点。

错误分类（50 条错误，不只报一个总数）

类型	条数	典型模式
A 排序对但分数<0.40	23	竣工图/图号稀释，排对了但分不够
B1 文种相近被顶替	17	开工报审 / 施工方案压过验收记录
B2 主语相近但不同	7	水泥/砂/钢筋跟踪记录互相错配
B3 一条多份被另一卷顶替	1	平断面图多份，卷册错配
B4 同分类号硬凑	2	文件夹兜底把不同文种抬到阈值以上

共 50 条：A 类 23、B 类 27。错误分析明细见附录。

幻觉率：先定义，再测量

「幻觉率」不是一个数，是一种口径。三个定义会测出三个不同的值；选一个作为验收口径，另外两个作为诊断项。

无依据陈述率 | 引用不匹配率 | 过度推断率

无依据陈述率 本页采用

原始 1/14 = 7.1%；引用闸门后 0/13 = 0%

定义：回答里的每个结论，能否在原文找到依据；找不到即计为无依据。

怎么测：15 条人工复核，逐条核对引用；分母为最终确定性结论。

适用：最严格，适合验收场景。

实测来自 15 条人工复核（2026-10-30，DeepSeek deepseek-chat，30 次调用）；原计划 30 条，样本不足，且同批样本曾用于调规则，不能当泛化幻觉率。

本门判断

如果只能报一个数，就报「在这个阈值下，会漏多少、会错多少」。**P 和 R 分开说，F1 只做汇总。**

本门决定 · 有条件放行　有条件通过：可作为「辅助自查」上线；不可作为「自动判定」。

R 仅 35%–64%，不承诺召回　跨项目必须重校准　高置信线 0.62，疑似带人工确认

05

系统

常规软件质量过关吗?

通过

> bug 闭环不是「修好了」，是「同一个 bug 不会再回来」。

测试矩阵

类型	方法	用例数	结果
功能	等价类 + 边界：导入 / 解析 / 检查 / 导出	28 条	26 通过；2 个 P2 已修复回归
异常	空目录、损坏文件、超大文件、中文路径	12 条	11 通过；空目录提示已修
性能	16 份扫描件全流程计时	3 轮	OCR 约 77 秒；全流程单次 18 分钟
兼容	docx / pdf / 扫描件 / Windows 内网	8 条	7 通过；中文路径 1 个已修
安全	本地处理、不上传、无外联	4 条	4 通过（本地处理、无外联）

Bug 台账（8 条真实记录，完整版见 docs/bugs.xlsx）

ID	严重级	发现阶段	根因	修复	回归	状态
BUG-001	P1	UAT	文件名含特殊字符解析失败	修复	回归通过	已关闭
BUG-002	P2	系统测试	导出列顺序不稳定	修复	回归通过	已关闭
BUG-003	P2	需求评审	手写签名无法识别	不修复	—	不修复（won't fix）
BUG-004	P1	系统测试	中文路径下 OCR 临时文件写入失败	临时目录 + 路径转义	回归通过	已关闭
BUG-008	P2	UAT	导出表合并单元格导致筛选失效	取消合并，冻结首行	待回归	已修复，待回归

每个关闭必须有回归证据；没有回归的「已修复」不算闭环。完整台账见 docs/bugs.xlsx（8 条真实记录；6 已关闭、1 won't fix、1 待回归）。

一个 won't fix 的理由

手写签名识别：准确率不可控，且**不改变验收结论**（系统只判断「有没有这份资料」，不判断签字真伪）。做了会增加误报和解释成本，所以明确不做。

本门判断

P0/P1 未闭环，不放行。**系统质量是放行的地板，不是加分项。**

本门决定 · 放行　通过：P0/P1 全部闭环；won't fix 有书面理由。

bug 台账归档（8 条真实记录）　回归用例入库　已知限制写进发布说明

06

UAT

用户能独立完成吗?

有条件

> UAT 不是演示给用户看，是让用户在没有我的情况下走完。

UAT 脚本（3 个任务，2026-10-31）

任务	输入	预期	通过标准	实际
导入一套资料	一套脱敏目录	看到总览与检查进度	无需指导完成，≤5 分钟	完成，4 分 20 秒，0 次求助
找到 3 个缺项并说明依据	已导入资料	每条缺项带条款与原文位置	3/3 能找到依据	3/3 找到；第 2 条耗时 2 分 10 秒
导出整改表	检查结果	Excel 可打开、列完整	字段齐全、可交给施工方	导出成功，字段齐全

UAT 时只观察，不提示；记录求助次数、卡点、原话。记录来自 2026-10-31 UAT；1 人，不能证明普遍可用。

观察记录（2026-10-31）

- 参与人数：1 位一线资料员（3 年经验）；2026-10-31，佛山 真实项目数据
- 求助次数：2 次，均在导出环节 真实项目数据
- 关键卡点：术语「归档范围」、导出列太多、合并单元格无法筛选 真实项目数据
- 用户原话：「归档范围」我不太懂，是不是就是应归档的意思? 真实项目数据
- 最费劲的步骤：导出（列多 + 筛选）；最希望先改：默认列少一点 真实项目数据

问题 → 修复 → 复测

问题	修复	复测结果
「归档范围」看不懂	改为「应归档」+ 一个示例	复测通过（能复述含义）
导出列太多	默认 5 列，其余折叠	复测通过（未再要求展开）
错误提示「匹配失败」	改为「未找到，建议人工确认」	复测通过（知道要人工确认）
导出表合并单元格导致筛选失效	取消合并，冻结首行	待回归（BUG-008）

样本局限

只有 **1 位**用户。它能发现阻塞问题，不能证明「用户普遍可用」。下一步扩到 3 位，覆盖不同熟练度。

本门判断

用户需要你在旁边才用得下去，就不算通过 UAT。**UAT 的通过标准是「没有你也能走完」。**

本门决定 · 有条件放行 有条件通过：1 位用户完成 3 个任务，4 个问题已修，BUG-008 待回归；样本待扩。

扩到 3 位用户　补新手引导　BUG-008 回归

07

上线后

变差了你多久能发现?

通过

> 上线不是结束，是评测集开始变脏的第一天。

上线后监控

指标	频率	阈值 / 动作	负责人
人工抽检 P	每周 50 条	P < 85% → 复核并考虑回滚	产品负责人（暂定）
人工复核率	每周	连续 2 周 > 40% → 查阈值/数据	产品负责人（暂定）
平均处理时长	每周	> 30 分钟 → 查性能	产品负责人（暂定）
延迟 P95	每日	> 1200秒 → 降级	产品负责人（暂定）
单次成本	每月	> ¥5/次 → 缩范围	产品本人（暂定）

badcase → eval case 的闭环

- 用户反馈 / 人工复核发现错误 → 进 badcase 库 自建评测
- 每周归类：漏报 / 误配 / 无法判定 自建评测
- 转成 eval case，进版本回归集 自建评测
- 新版本必须跑回归，老 case 不能回退 自建评测

回滚条件（写死，不临场讨论）

条件	动作
抽检 P 掉 5 个点以上	回滚上一版本
延迟翻倍	降级到规则模式 / 回滚
误报率超过10%	暂停自动提示，只保留清单
新项目未重校准阈值	禁止上线，先校准

本门判断

没有监控的上线，不是上线，是失联。**先定义「怎么发现变差」，再谈发布。**

本门决定 · 放行　通过（设计完成）：监控指标、抽检频率、回滚条件均已定义。

周报模板　badcase 库　版本台账

---

08 / 放行判定

放行判定书

七道门走完，签字之前，把所有「有条件」写清楚。不是「成功上线」，是「有条件放行」。

RELEASE DECISION

有条件放行

定位为辅助自查，不替代人工审核；对外不承诺召回率。

闸门	结论	理由
G1 需求	● 通过	3 条需求可写成 Given/When/Then；1 条被拒并留痕；3 场访谈已完成（2026-11-03）
G2 方案	● 通过	AI 只做辅助，人工兜底明确
G3 数据	● 有条件	单人标注，无 Kappa
G4 模型	● 有条件	严格 R 仅 35%；跨项目衰减 3.5–12.9 点
G5 系统	● 通过	P0/P1 全闭环；won't fix 有理由
G6 UAT	● 有条件	仅 1 位用户；4 个问题已修，BUG-008 待回归

闸门	结论	理由
G7 上线后	● 通过	监控与回滚条件已定义

放行条件（写死，不临场讨论）

1. 定位为「辅助自查」，不替代人工审核；系统不签字。
2. ≥0.62 直接提示；0.40–0.62 必须人工确认；<0.40 明确说「未找到」。
3. 每周抽检 50 条；抽检 P 掉 5 个点即回滚。
4. 换项目必须重校准阈值，不得直接复用。
5. 对外不承诺召回率；只说「20 分钟内给出缺项清单，附依据供核对」。

> **如果按「自动判定」卖，会发生什么**
>
> 35% 的召回意味着用户会漏项，而漏项在竣工验收里是返工和延期——这个责任产品承担不了。所以不放行「自动判定」，只放行「辅助自查」。

产品负责人 / 验收人：刘恺希　　日期：2026-11-03

---

09 / 路线图　下一道门，不是下一个功能

每个阶段都有量化验收标准和放弃条件；不写「未来展望」。

阶段	目标	验收标准	放弃条件
P0 辅助自查	人找系统确认	20 分钟内出缺项清单	用户仍要全量人工翻 → 停
P1 半自动	系统给疑似 + 人工复核	人工复核时间降 50%	复核率不降 → 停
P2 跨项目复用	同一套门换项目	新项目重校准后 F1 ≥ 65%	两个项目都达不到 → 停

P2 的 65% 不是拍脑袋：项目B自校准 F1 只有 62.3%，说明换项目后要先接受一个更低的基线，再谈提升。

---

10 / 附录　证据索引

每个结论都能回到一份文件。没有证据的，标「待填」，不假装有。

证据	内容	来源
预测明细.csv	251 行逐条预测：分数、top1、标注答案	真实项目数据
跨项目结果.csv	阈值迁移与重校准对比	真实项目数据
消融结果.csv	同义词 / 文件夹后缀的贡献	真实项目数据
错误分析.csv	50 条错误分类与典型样本	真实项目数据
标注表.xlsx	候选池与人工标注（有/无/疑似）	真实项目数据
PRD（含验收标准章节）	docs/PRD.md（v1.0，含验收标准章节）	真实项目数据
访谈记录	docs/interviews.md（3 场，2026-11-03，佛山）	真实项目数据
UAT 记录	docs/uat.md（1 人 3 任务，2026-10-31，佛山）	真实项目数据
Bug 台账	docs/bugs.xlsx（8 条真实记录，含 1 条待回归）	真实项目数据

电力项目资料已脱敏；页面不展示真实工程文件，只展示统计结果与合成样例。

七道闸门 · 一个 AI 产品的验收实录

个人作品集 · 数据来自自建项目 T1-02 的评测记录；估算与单样本口径均标注，未以估算冒充实测。

生成日期：2026-11-03